Đánh giá và cải tiến truy xuất bằng chứng pháp lý cho hỏi đáp pháp luật Việt Nam

Nghiên cứu trên VLSP 2025 DRiLL

Nhóm 18

Lê Minh Nhựt – 26848158
Phan Văn Thắng – 26848203
Phan Tiến – 26848224

Giảng viên hướng dẫn
TS. Hà Minh Tân

Báo cáo đồ án



Nội dung

1. Bối cảnh và bài toán
2. Dữ liệu và độ đo
3. Phương pháp và kết quả thực nghiệm
4. Kết luận



PHẦN 1

Bối cảnh và bài toán

Vì sao truy xuất pháp luật khó?

Thách thức truy xuất

- Văn bản dài, nhiều tầng Điều–Khoản–Điểm.
- Ngôn ngữ pháp luật có chứa nhiều thuật ngữ đặc thù.
- Câu hỏi có thể khác cách diễn đạt với văn bản luật.
- Một câu hỏi có thể cần nhiều điều luật làm bằng chứng.

VĂN BẢN PHÁP LUẬT

Minh họa cấu trúc

Điều 1. [Tên điều]

1. [Nội dung khoản 1]
   a) [Nội dung điểm]
   b) [Nội dung điểm]
2. [Nội dung khoản 2]



Phát biểu bài toán

Đầu vào

Câu hỏi

VD: Viên chức có được tạm hoãn nghĩa vụ quân sự không?

Tài liệu: các điều luật (aid) được lập chỉ mục.

→

Xử lý

1. **Truy xuất** các điều ứng viên.
2. **Chấm điểm và xếp hạng** mức liên quan với câu hỏi.
3. **Chọn số điều** trả về.

→

Đầu ra mong muốn

Danh sách các điều ứng viên liên quan

aid 55075

aid 4993

Mục tiêu thực tế

Tìm **đúng và đủ các điều luật liên quan** để làm bằng chứng cho câu trả lời.



Câu hỏi nghiên cứu

1. Biểu diễn điều luật thế nào để truy xuất hiệu quả?
2. Kết hợp truy xuất từ vựng và ngữ nghĩa, rồi xếp hạng lại có cải thiện kết quả không?
3. Kết hợp các tín hiệu bằng LightGBM có cải thiện thứ hạng không?
4. Chọn số điều trả về theo từng câu hỏi có tốt hơn số lượng cố định không?



PHẦN 2

Dữ liệu và độ đo

Cấu trúc dữ liệu gốc

Mẫu JSON · Luật 102/2016/QH13

```
{
  "id": 226,
  "law_id": "102/2016/QH13",
  "content": [
    {
      "aid": 6412,
      "content_Article": "Trẻ em là người dưới 16 tuổi."
    }
  ]
}
```

- **WeDev-VLSP:** văn bản pháp luật được tổ chức thành các trường thông tin như mã văn bản, mã Điều và nội dung Điều.
- **Đơn vị truy xuất:** dữ liệu đã chia đến cấp Điều; mỗi Điều có mã *aid* và nội dung riêng.



DRiLL 2025: thống kê dữ liệu

Train · 1.752 câu hỏi

19,78	1,34
Từ / câu	Điều gold / câu
min 6 · max 45	min 1 · max 9

Dev · 438 câu hỏi

19,46	1,35
Từ / câu	Điều gold / câu
min 11 · max 45	min 1 · max 7

Public · 312 câu hỏi

20,00	1,31
Từ / câu	Điều gold / câu
min 11 · max 42	min 1 · max 4

Private · 627 câu hỏi

19,90	1,32
Từ / câu	Điều gold / câu
min 11 · max 44	min 1 · max 5

Tài liệu pháp luật

2.157 văn bản **59.628 Điều**



Precision và Recall: đúng đến đâu, đủ đến đâu?

Với P_q là tập Điều luật hệ thống trả về; G_q là tập Điều luật đúng (gold) của câu hỏi q.

Precision · độ chính xác

$$\frac{|P_q \cap G_q|}{|P_q|}$$

Trong các Điều được trả về, có bao nhiêu Điều liên quan?

Recall · độ bao phủ

$$\frac{|P_q \cap G_q|}{|G_q|}$$

Trong các Điều liên quan, hệ thống tìm được bao nhiêu?

Ký hiệu @k

Chỉ xét k vị trí đầu của danh sách xếp hạng. Ví dụ, Recall@50 đo tỷ lệ Điều gold xuất hiện trong 50 ứng viên đầu.

Macro-F2: cân bằng độ chính xác và độ bao phủ

Cách DRiLL tính chỉ số

$$P_{macro} = \frac{1}{Q}\sum_q P_q, \qquad R_{macro} = \frac{1}{Q}\sum_q R_q$$

$$\text{Macro-}F_2 = \frac{5\,P_{macro}\,R_{macro}}{4\,P_{macro}+R_{macro}}$$

Macro

Mỗi câu hỏi đóng góp như nhau vào Precision và Recall tổng hợp.

F2

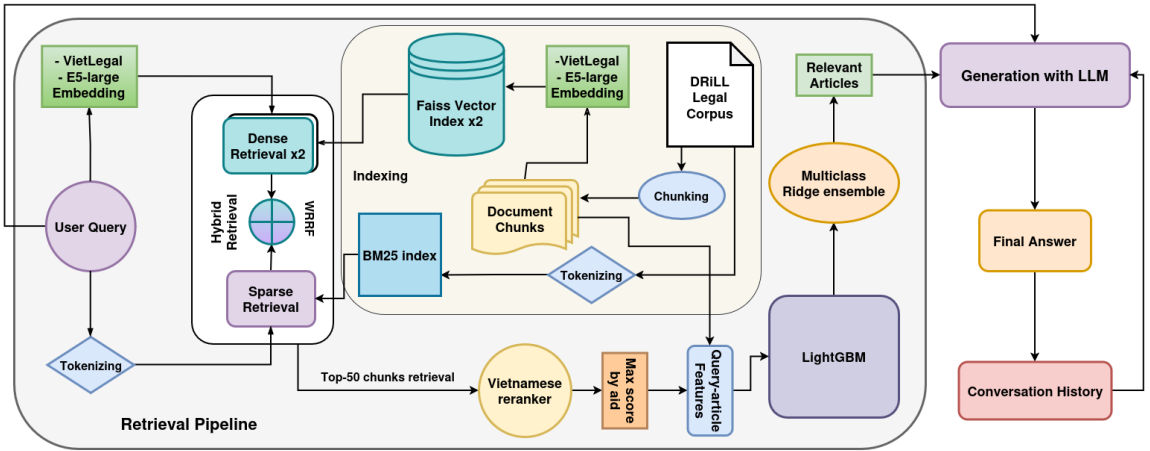
Recall được ưu tiên hơn Precision; hệ thống vẫn cần hạn chế trả về Điều không liên quan.



PHẦN 3

Phương pháp và kết quả thực nghiệm

Pipeline tổng thể



Vì sao cần biểu diễn văn bản trước khi truy xuất?

Biểu diễn văn bản giúp lập chỉ mục để tìm Điều luật theo mức độ khớp từ ngữ hoặc ngữ nghĩa.

Tín hiệu thưa (Sparse) · chỉ mục từ khóa

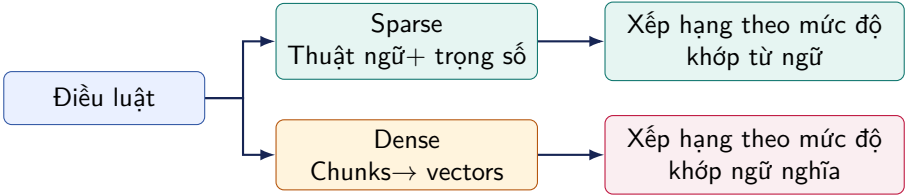
Biểu diễn điều luật bằng **thuật ngữ và trọng số**.

Tìm theo **từ khóa trùng khớp** với câu hỏi.

Tín hiệu dày (Dense) · chỉ mục vector

Mã hóa các chunk thành **vector ngữ nghĩa**.

Tìm theo **ý nghĩa**, dù cách diễn đạt khác nhau.



Chunking cho mô hình dense

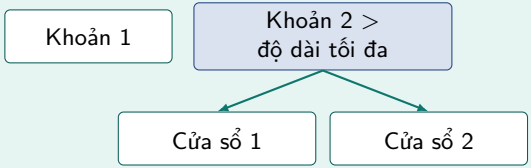
1. Cắt cụt điều luật (Article truncation)

Mỗi Điều là một chunk, tuy nhiên phần vượt quá chiều dài tối đa của mô hình sẽ bị cắt (512 token).



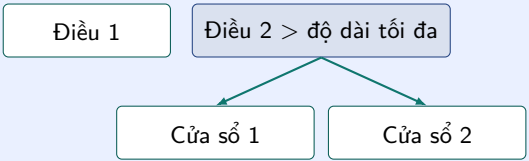
2. Cửa sổ trượt theo Khoản (Clause window)

Mỗi Khoản là một chunk; Khoản dài hơn giới hạn được chia thành các cửa sổ 448 token, chồng lấp 64.



3. Cửa sổ trượt theo Điều (Article window)

Mỗi Điều là một chunk; Điều dài hơn giới hạn được chia thành các cửa sổ 448 token, chồng lấp 64.



Ablation chunking ở giai đoạn truy xuất

Bảng 1. So sánh cách chunking tại giai đoạn truy xuất, dựa trên mô hình VietLegal-Harrier

Biểu diễn	Precision@2	Recall@2	Macro-F2@2	Recall@50	Recall@100
Article truncation (512)	0.3368	0.5732	0.5026	0.9125	0.9422
Clause window (448/64)	0.3345	0.5742	0.5022	0.9186	0.9471
Article window (448/64)	**0.3425**	**0.5808**	**0.5098**	**0.9256**	**0.9517**

Trong ba cách biểu diễn, Article window đạt các chỉ số cao nhất, đặc biệt là Recall@50.
Giữ lại phần văn bản bị bỏ qua khi cắt cụt; điểm các chunk được gộp về cấp Điều.



Từ nhánh đơn đến truy xuất lai (hybrid retrieval)

Sparse

Khớp từ khóa.

BM25

$$\mathrm{BM25}(q,d) = \sum_{t \in q} \mathrm{IDF}(t)\, w(t,d)$$

$$w(t,d) = \frac{f(t,d)(k_1+1)}{f(t,d) + k_1\left(1 - b + b\frac{|d|}{\mathrm{avgdl}}\right)}$$

Dense

Khớp ngữ nghĩa

Nhánh 1 · VietLegal-Harrier

Nhánh 2 · multilingual-E5-large

Hybrid

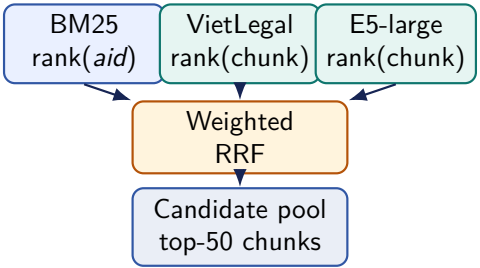
Bổ sung đa tín hiệu

Weighted RRF
Hợp nhất thứ hạng từ các nhánh.

Mỗi nhánh lấy top-100; sau hợp nhất chọn top-50 cho reranker.



Weighted RRF: hợp nhất thứ hạng



Công thức WRRF

$$S(c) = \sum_{m \in \mathcal{M}} \frac{w_m}{k + r_m(c)}$$

- c: chunk; $aid(c)$: Điều cha. BM25 xếp Điều, dense xếp chunk.
- r_m: hạng trong nhánh m (1 đứng đầu); thiếu hạng thì đóng góp 0.
- $\mathcal{M}$: tập nhánh; w_m: trọng số; k: hằng số làm mượt hạng.

Ablation ở giai đoạn truy xuất: thành phần nào hữu ích?

Bảng 2. Truy xuất đơn/lai · Article window 448/64 · top-100/nhánh · WRRF $k = 10$

Trọng số BM25/Harrier: 0.19/0.81; Harrier/E5: 0.76/0.24; cả ba: 0.15/0.65/0.20.

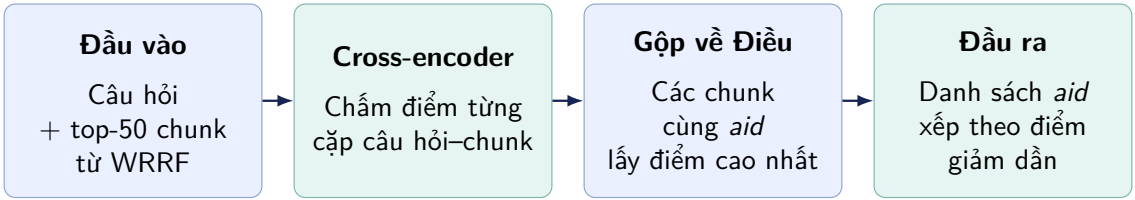
Thành phần truy xuất	Precision@2	Recall@2	Macro-F2@2	Recall@50
BM25	0.2511	0.4297	0.3762	0.8348
VietLegal-Harrier	0.3425	0.5808	0.5098	0.9256
multilingual-E5-large	0.3174	0.5347	0.4703	0.9106
BM25 + VietLegal	0.3482	0.5846	0.5147	0.9338
VietLegal + E5-large	0.3539	0.5934	0.5227	0.9350
BM25 + VietLegal + E5-large	**0.3573**	**0.5951**	**0.5252**	**0.9387**

Kết hợp cả ba nhánh đạt Macro-F2@2 và Recall@50 cao nhất trong so sánh.



Cross-encoder: chấm lại mức liên quan với câu hỏi

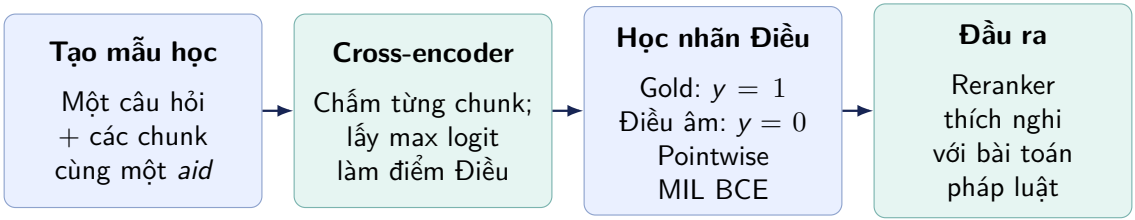
Đọc **câu hỏi và chunk cùng lúc** để phân biệt các ứng viên đã truy xuất.



Lưu ý: 50 chunk có thể thuộc ít hơn 50 điều; mỗi cặp đầu vào tối đa 512 token.

Fine-tuning reranker: học từ nhãn Điều luật

1.752 câu hỏi train; nhãn liên quan ở cấp Điều, chưa có nhãn riêng cho từng chunk.



- **Mẫu dương:** lấy chunk của điều gold, bổ sung nếu thiếu trong ứng viên train.
- **Mẫu âm:** teacher chọn điều không thuộc gold nhưng có điểm cao, dễ gây nhầm.



Ablation cho giai đoạn xếp hạng

Bảng 3. Tác động của reranking · Article window 448/64 · cùng truy xuất lai

Giai đoạn / mô hình	Precision@2	Recall@2	Macro-F2@2
Chỉ truy xuất lai thuần	0.3573	0.5951	0.5252
Cross-encoder, chưa fine-tune	0.3995	0.6623	0.5853
Cross-encoder, fine-tune epoch 1	**0.4064**	**0.6759**	**0.5967**

Reranking cải thiện Precision và Recall; fine-tuning tiếp tục nâng kết quả ở top-2.



LightGBM: xếp hạng Điều luật theo câu hỏi

Với một câu hỏi, điều luật nào nên được xếp cao hơn?



57 đặc trưng: điểm/hạng · đồng thuận truy xuất · thống kê chunk · khớp từ.

q: câu hỏi; *aid*: điều ứng viên. Khi học: $y = 1$ nếu điều thuộc gold, ngược lại $y = 0$.

Ablation tổng hợp tín hiệu xếp hạng với LightGBM

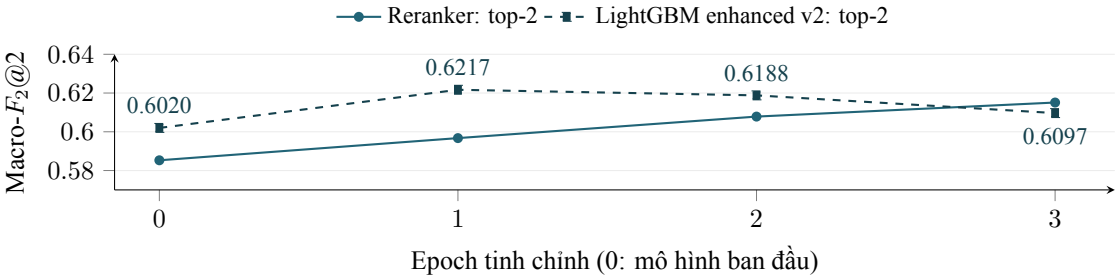
Bảng 4. So sánh reranker-only và các schema LightGBM tại fixed top-2

Mô hình	Số đặc trưng	Precision@2	Recall@2	Macro-F2@2
Cross-encoder fine-tune	0	0.4064	0.6759	0.5967
LightGBM `base_v1`	15	0.4201	0.7006	0.6180
LightGBM `enhanced_v1`	37	0.4189	0.6957	0.6145
LightGBM `enhanced_v2`	57	**0.4269**	**0.7017**	**0.6217**
LightGBM `enhanced_v3`	65	0.4224	0.6916	0.6134

enhanced_v2 đạt Precision@2, Recall@2 và Macro-F2@2 cao nhất trong các schema đã so sánh.



Chọn epoch theo kết quả sau LightGBM



Nhận xét với cùng đầu ra top-2

Epoch 3 dẫn đầu khi chỉ dùng reranker (**0.6151**), còn epoch 1 đạt cao nhất sau LightGBM enhanced v2 (**0.6217**). Kết quả này hỗ trợ chọn epoch 1 cho pipeline.

Chính sách chọn số Điều luật đầu ra

Danh sách LightGBM đã xếp hạng → chọn top-k điều theo câu hỏi.

1. **Fixed top-k:** Luôn trả về k điều đứng đầu.
2. **Score gap:** Chọn điểm dừng dựa trên chênh lệch điểm giữa các điều liền kề.
3. **Fold-safe learned stopping:** Dự đoán nên lấy thêm hay dừng tại từng vị trí.
4. **Multiclass–Ridge:** Chấm các lựa chọn top-1 đến top-5 bằng hai mô hình, rồi chọn độ dài tốt nhất.



Kết quả thực nghiệm các chính sách chọn đầu ra

Bảng 5. Bốn chính sách trên dev với LightGBM enhanced_v2

Chính sách	Precision	Recall	Macro-F2
Fixed top-2	0.4269	0.7017	0.6217
Score gap	0.5689	0.7076	0.6747
Fold-safe learned stopping	0.5243	**0.7303**	0.6771
Multiclass–Ridge ensemble	**0.5757**	0.7274	**0.6910**

Multiclass–Ridge đạt Macro-F2 cao nhất; learned stopping đạt Recall cao nhất.



Đối chiếu kết quả trên DRiLL

Bảng 6. Macro-F2 toàn hệ thống trên public/private test; đối chiếu tham khảo

Hệ thống	Public F2	Private F2
EDM	0.5982	**0.7261**
FPT IS	**0.7426**	0.6966
CUDO	0.7345	0.6955
Nhóm 18	0.6978	0.6825
Berry	0.4456	0.6710
IUH.TD	0.6337	0.6521
brain_rot	0.7032	0.6495
AImba	0.6473	0.6425
Baseline two-stage (BTC)	–	0.5512
Baseline BM25 (BTC)	0.2771	0.3365

PHẦN 4

Kết luận

Kết luận: đóng góp của từng tầng trong pipeline

Các mốc dev/OOF

Truy xuất lai
Article window 448/64; BM25 + hai dense tìm ứng viên

F2@2: **0.5252**

→

Reranker
Học mức liên quan; chấm chunk, gộp max về điều

F2@2: **0.5967**

→

LightGBM
Kết hợp 57 tín hiệu để xếp lại các điều luật

F2@2: **0.6217**

→

Multiclass–Ridge
Chọn số điều phù hợp với từng câu hỏi

F2: **0.6910**

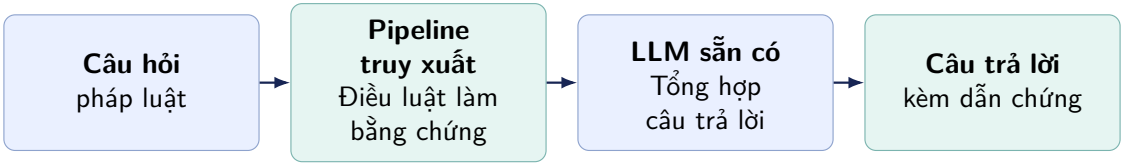
Kết quả Codabench

Macro-F2: **0.6978 public** · **0.6825 private**

Khác biệt phương pháp với các đội điểm cao hơn

Chưa dùng tiêu đề/đặc trưng LLM như EDM và tăng cường dữ liệu LLM như FPT IS. Chưa xác định các khác biệt này giải thích bao nhiêu chênh lệch điểm.

Demo hỏi đáp pháp luật



- **Trọng tâm đồ án là truy xuất:** tìm đúng và đủ bằng chứng, tạo nền tảng cho chất lượng trả lời của hệ thống RAG.
- **Demo tận dụng LLM sẵn có** để minh họa ứng dụng hỏi đáp từ các điều luật đã chọn.
- Các thành phần sinh câu trả lời và giao diện hội thoại phục vụ demo; **chưa đánh giá sâu chất lượng câu trả lời**.

Cảm ơn thầy và các bạn!

Nhóm 18

Trao đổi và câu hỏi