Đánh giá và cải tiến truy xuất bằng chứng pháp lý cho hỏi đáp pháp luật Việt Nam

Nghiên cứu trên VLSP 2025 DRiLL

Nhóm 18

Lê Minh Nhựt – 26848158
Phan Văn Thắng – 26848203
Phan Tiến – 26848224

Giảng viên hướng dẫn
TS. Hà Minh Tân

Báo cáo đồ án



Nội dung

1. Bối cảnh và bài toán
2. Dữ liệu và độ đo
3. Phương pháp và ablation
4. Kết luận



PHẦN 1

Bối cảnh và bài toán

Vì sao truy xuất pháp luật khó?

Thách thức truy xuất

- Văn bản dài, nhiều tầng Điều–Khoản–Điểm.
- Ngôn ngữ pháp luật có thuật ngữ và cách diễn đạt đặc thù.
- Câu hỏi có thể khác cách diễn đạt với văn bản luật.
- Một câu hỏi có thể cần nhiều điều luật làm bằng chứng.

VĂN BẢN PHÁP LUẬT

Điều 8. [Tên điều]

1. [Nội dung khoản]
   a) [Nội dung điểm]
   b) [Nội dung điểm]
2. [Khoản tiếp theo]

Mục tiêu thực tế

Tìm **đúng và đủ** nhiều Điều luật liên quan nhất có thể trước khi đưa cho hệ thống trả lời hoặc giải thích.

Phát biểu bài toán

Đầu vào

Câu hỏi (q)

Viên chức có được tạm hoãn nghĩa vụ quân sự không?

Kho văn bản (chứa các d): 59.628 Điều đã lập chỉ mục

Chấm điểm và xếp hạng

Mỗi Điều trong kho nhận điểm liên quan $s(q, d)$; mô hình xếp hạng các Điều theo điểm số.

aid 55075 · Luật 78/2015/QH13
"Tạm hoãn gọi nhập ngũ..."

aid 4993 · Luật 48/2019/QH14
"Sửa đổi, bổ sung Luật Nghĩa vụ quân sự..."

Đầu ra mong muốn

aid 55075
aid 4993

Ví dụ dùng qid 730 và hai aid gold trong train.



Câu hỏi nghiên cứu

Bốn câu hỏi được đặt ra:

1. Biểu diễn và lưu trữ văn bản pháp luật như thế nào để truy xuất hiệu quả?
2. Xây dựng thành phần truy xuất và xếp hạng điều luật ra sao?
3. Làm sao để tận dụng và kết hợp các tín hiệu truy xuất lại với nhau để cho kết quả tốt hơn?
4. Chọn số điều luật phù hợp để trả về cho mỗi câu hỏi như thế nào?



PHẦN 2

Dữ liệu và độ đo

DRiLL 2025: dữ liệu sử dụng

Số lượng câu hỏi:

Train · 1.752 câu

19,78	**1,34**
Từ / câu	Điều gold / câu
min 6 · max 45	min 1 · max 9

Dev · 438 câu

19,46	**1,35**
Từ / câu	Điều gold / câu
min 11 · max 45	min 1 · max 7

Public · 312 câu

20,00	**1,31**
Từ / câu	Điều gold / câu
min 11 · max 42	min 1 · max 4

Private · 627 câu

19,90	**1,32**
Từ / câu	Điều gold / câu
min 11 · max 44	min 1 · max 5

Corpus (thông tin cần truy xuất): 2.157 văn bản · 59.628 Điều

Chia dữ liệu và chống rò rỉ

TRAIN	DEV	PUBLIC TEST	PRIVATE TEST
1.752 câu	438 câu	312 câu	627 câu
Tạo cặp train Fine-tune reranker	**Chọn cấu hình Chọn chính sách**	**Báo cáo benchmark**	**Đánh giá cuối cùng**

Giao thức chống rò rỉ

Corpus gồm 59.628 Điều, là kho ứng viên dùng cho các bước truy xuất và xếp hạng.
Seed cố định: 42; danh sách qid của split train/dev được lưu để tái lập.



Precision và Recall: đúng đến đâu, đủ đến đâu?

Precision · độ chính xác

$$\frac{|P_q \cap G_q|}{|P_q|}$$

Trong các Điều được trả về, có bao nhiêu Điều liên quan?

Recall · độ bao phủ

$$\frac{|P_q \cap G_q|}{|G_q|}$$

Trong các Điều liên quan, hệ thống tìm được bao nhiêu?

Ký hiệu @k

Chỉ xét k vị trí đầu của danh sách xếp hạng. Ví dụ, Recall@50 đo tỷ lệ Điều gold xuất hiện trong 50 ứng viên đầu trước reranker.

P_q: Điều hệ thống trả về; G_q: Điều gold của câu hỏi q.



Macro-F2: cân bằng độ chính xác và độ bao phủ

Cách DRiLL tính chỉ số

$$P_{macro} = \frac{1}{Q}\sum_q P_q, \qquad R_{macro} = \frac{1}{Q}\sum_q R_q$$

$$F_2 = \frac{5\,P_{macro}\,R_{macro}}{4\,P_{macro}+R_{macro}}$$

Macro

Mỗi câu hỏi đóng góp như nhau vào Precision và Recall tổng hợp.

F2

Recall được ưu tiên hơn Precision; hệ thống vẫn cần hạn chế trả về Điều không liên quan.

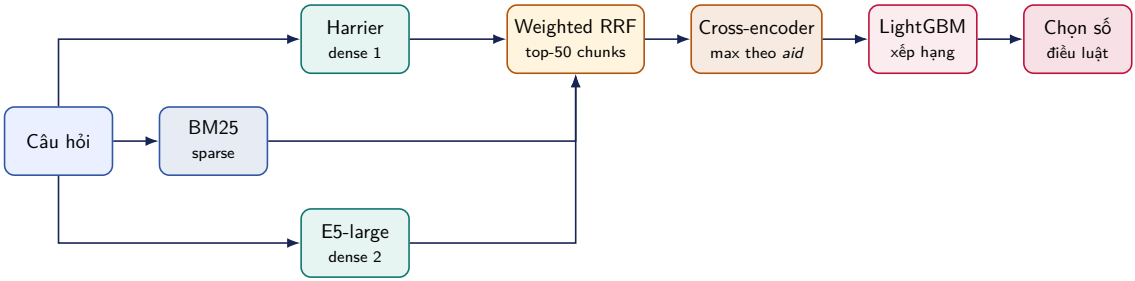
F2 được tính từ hai giá trị macro; không lấy trung bình F2 riêng của từng câu hỏi.



PHẦN 3

Phương pháp và ablation

Pipeline tổng thể



Cấu hình chốt đã nộp

Fixed window 448/64 · references off · WRRF10 (0.15 / 0.65 / 0.20) · top-50.

Baseline: BM25 và dense retrieval

Các nhánh truy xuất

- BM25/VnCoreNLP: khớp từ vựng, baseline sparse.
- VietLegal-Harrier: dense encoder chuyên biệt.
- multilingual-E5-large: dense encoder đa ngôn ngữ.
- Hybrid kết hợp thứ hạng thay vì cộng raw score khác thang đo.



Ablation first-stage: thành phần nào hữu ích?

First-stage	Macro-F2@2	Recall@50
BM25 + VnCoreNLP	0.3762	0.8348
Harrier	0.5098	0.9256
E5-large	0.4703	0.9106
BM25 + Harrier	0.5147	0.9338
Harrier + E5	0.5227	0.9350
BM25 + Harrier + E5	**0.5252**	**0.9387**

Cách đọc

Các nhánh đơn lẻ được đo riêng; tổ hợp dùng cùng component rankings, trọng số được cross-fit trên dev.



Chọn độ sâu candidate: vì sao top-50?

- Top-50 đạt candidate recall đủ cao cho reranker.
- So với top-100, giảm khoảng một nửa số chunk cần chấm.
- Giảm chi phí tính toán mà giữ chất lượng downstream tốt.

Trade-off

Recall đủ dùng

$$50 < 100$$

xấp xỉ nửa khối lượng rerank

Ghi chú: diễn giải theo kết quả depth study; không suy ra chi phí end-to-end giảm đúng 50%.



Chunking: giả thuyết ban đầu

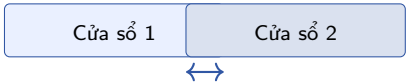
Chunk theo cấu trúc

- Giữ Khoản/Điểm và ngữ cảnh pháp lý
- Kỳ vọng evidence rõ hơn



Fixed token window

- 448 token, overlap 64
- Đơn giản, bao phủ đều văn bản



Mỗi cửa sổ dài 448 token; phần chồng lấp giữa hai cửa sổ là 64 token.

Ablation chunking ở first-stage

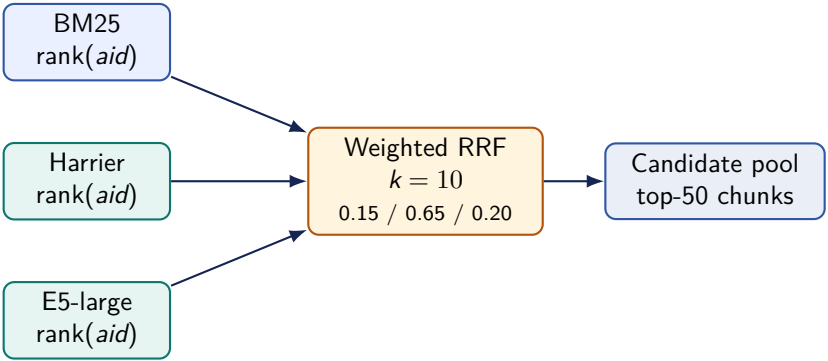
Biểu diễn	Macro-F2@2	Recall@100
Article truncation	0.5026	0.9422
Khoản + fallback 448/64	0.5022	0.9471
Khoản–Điểm 448/64	0.5079	0.9463
Fixed window 448/64	**0.5098**	**0.9517**

Kết quả bất ngờ

Fixed window được chọn: tốt nhất về Macro-F2@2 và Recall@100 trong bốn cách biểu diễn đã thử.



Weighted RRF: kết hợp thứ hạng, không cộng raw score



Vì sao dùng RRF?

Mỗi retriever đóng góp theo vị trí xếp hạng; khác biệt thang điểm BM25 và cosine không chi phối phép trộn.

Fusion: trọng số được chọn trên dev

Cấu hình fusion được chọn

- Dùng 5-fold cross-fitting để chọn trọng số first-stage.
- WRRF $k = 10$: BM25/Harrier/E5 $= 0.15/0.65/0.20$.
- Private không tham gia chọn trọng số.



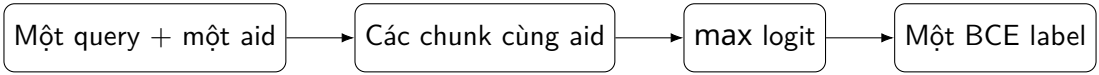
Cross-encoder reranking

Luồng reranking

1. Lấy top-50 fused chunks.
2. Chấm cặp câu hỏi–chunk bằng cross-encoder.
3. Max-aggregate chunk scores về một score cho mỗi *aid*.
4. Xếp hạng article.



Fine-tuning: article-level MIL



Chunk thuộc nhiều article trong candidate pool, nhưng mỗi MIL bag chỉ gom chunk của cùng một *aid*.

Fine-tuning: trạng thái bằng chứng

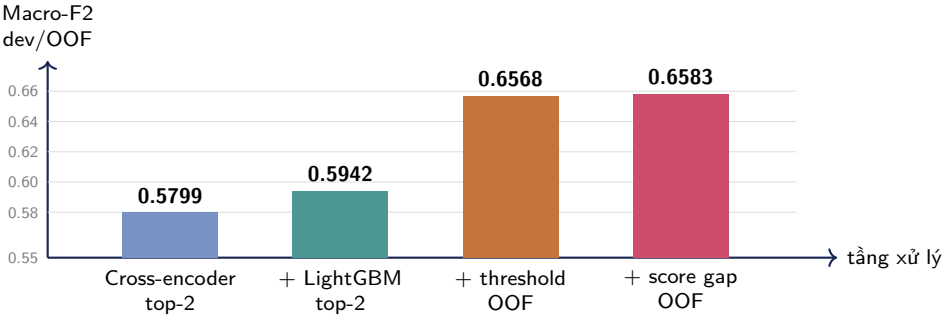
Những gì đã xác nhận

- Checkpoint 1208 được fine-tune trên bag Khoản–Điểm.
- Pipeline fixed-window hiện dùng checkpoint đó: đây là transfer giữa hai biểu diễn.
- Thử nghiệm fine-tune fixed-window 3 epoch đang chạy; chưa đưa thành kết quả.



Từng tầng làm thay đổi kết quả ra sao?

Các mốc dev/OOF để kể tiến trình pipeline; đây không phải ablation một biến duy nhất.



Diễn giải: Chọn số điều luật là bài toán riêng; các mốc kể tiến trình, không phải ablation một biến.

LightGBM: kết hợp tín hiệu reranker

Tín hiệu đầu vào

- Điểm/thứ hạng từ retriever
- Score cross-encoder và chênh lệch trong query
- Tín hiệu từ query, chunk và article

Huấn luyện có kiểm soát

- 61 đặc trưng (`enhanced_v2`)
- Chia fold theo query
- OOF dùng để chọn chính sách đầu ra

LightGBM học sắp hạng lại candidate; chính sách cardinality quyết định trả bao nhiêu article.



Chọn số điều luật: fixed, threshold, thích ứng

Fixed top-2

1 2 3 4

Luôn trả cùng số lượng.

Chọn theo từng truy vấn

1 2 3 4

Dừng khi lợi ích dự đoán giảm.

Quy tắc chống rò rỉ

Ngưỡng/chính sách học từ train và dev OOF; khóa trước khi chấm public/private.



Chính sách cardinality: dev OOF

Chính sách	Precision	Recall	Nested OOF F2
Balanced multiclass	0.5287	0.7299	0.6783
Multiclass–Ridge ensemble	0.5449	0.7280	0.6822
Cost-sensitive multiclass	0.2567	0.7966	0.5607

Ridge chọn $\lambda = 0.5$ trên dev; không dùng nhãn private để chọn.



Kết quả cuối đã ghi nhận

PUBLIC
0.7055
Macro-F2

PRIVATE
0.6735
Macro-F2

Cấu hình đã nộp

Fixed window 448/64 · references off · WRRF10 0.15/0.65/0.20 · LightGBM enhanced_v2 · multiclass–Ridge.

Submission 1026275 / 1026274. Private là kết quả báo cáo, không dùng để lựa chọn.



PHẦN 4

Kết luận

Kết luận chính

Thông điệp chính

1. Hybrid retrieval tạo candidate pool có recall cao.
2. Top-50 là điểm cân bằng chất lượng–chi phí theo thí nghiệm.
3. Fixed 448/64 thắng các biểu diễn cấu trúc đã so trong cấu hình cuối.
4. LightGBM và cardinality policy cải thiện chọn điều luật cuối.



Điều học được từ các kết quả âm

Candidate miss

Gold không vào top-50

mất cơ hội sửa ở sau

Xếp hạng sai

Gold có trong pool nhưng bị đẩy xuống

reranker / LightGBM

Chọn thiếu / thừa

Quyết định cardinality lệch

bỏ sót / false positive

Đây là khung phân tích lỗi; chưa gắn số vì audit R9 chưa hoàn tất.



Giới hạn và hướng tiếp theo

- Một benchmark và một split dev hữu hạn.
- Handoff/OOF và kết quả cần được lưu cùng provenance để tái lập.
- Đánh giá riêng fixed-window fine-tuning khi có checkpoint và dev run hoàn chỉnh.
- Phân tích lỗi theo candidate miss, reranker demotion, chọn thiếu/thừa.



Đặt kết quả vào bối cảnh DRiLL

Hệ thống / chính sách	Public F2	Private F2
Organizer two-stage, top-2	–	0.5512
ViDRILL (published)	–	0.6521
EDM (published)	–	0.7261
Project: fixed window + threshold	0.6669	0.6520
Project: fixed window + multiclass	0.6833	0.6677
Project: retuned WRRF + multiclass–Ridge	**0.7055**	**0.6735**

Cách diễn giải

Kết quả các đội là số công bố trên private; khác thời điểm và cấu hình nên không dùng bảng này để tuyên bố thứ hạng.



Nguồn dữ liệu và mã

Nguồn chính

- VLSP 2025 DRiLL shared task: dữ liệu, metric và kết quả baseline.
- Báo cáo đội tham gia: ViDRILL và EDM.
- Repository: mã nguồn, cấu hình, split và artifacts của project.

Tái lập

Các số trên slides được chép từ `tables_experiment.md`; kết quả submission có mã run đi kèm.



Tài liệu tham khảo

- Vuong et al. DRiLL Shared Task 2025: The Challenge of Deep Retrieval in the Expansive Legal Landscape. VLSP 2025.
- Robertson and Zaragoza. The Probabilistic Relevance Framework: BM25 and Beyond.
- Cormack, Clarke, and Buettcher. Reciprocal Rank Fusion outperforms Condorcet and individual rank learning methods.



Cảm ơn thầy và các bạn!

Nhóm 18

Trao đổi và câu hỏi