Đánh giá và cải tiến truy xuất bằng chứng pháp lý cho hỏi đáp pháp luật Việt Nam

Nghiên cứu trên VLSP 2025 DRiLL

Nhóm 18

Lê Minh Nhựt – 26848158
Phan Văn Thắng – 26848203
Phan Tiến – 26848224

Giảng viên hướng dẫn
TS. Hà Minh Tân

Báo cáo đồ án



Nội dung

1. Bối cảnh và bài toán
2. Dữ liệu và độ đo
3. Phương pháp và kết quả thực nghiệm
4. Kết luận



PHẦN 1

Bối cảnh và bài toán

Vì sao truy xuất pháp luật khó?

Thách thức truy xuất

- Văn bản dài, nhiều tầng Điều–Khoản–Điểm.
- Ngôn ngữ pháp luật có chứa nhiều thuật ngữ đặc thù.
- Câu hỏi có thể khác cách diễn đạt với văn bản luật.
- Một câu hỏi có thể cần nhiều điều luật làm bằng chứng.

VĂN BẢN PHÁP LUẬT

Điều 8. [Tên điều]

1. [Nội dung khoản 1]
   a) [Nội dung điểm]
   b) [Nội dung điểm]
2. [Nội dung khoản 2]

Mục tiêu thực tế

Tìm **đúng và đủ** nhiều Điều luật liên quan nhất có thể trước khi đưa cho hệ thống trả lời hoặc giải thích.

Phát biểu bài toán

Đầu vào

Câu hỏi (q)

Viên chức có được tạm hoãn nghĩa vụ quân sự không?

Kho văn bản (chứa các d): 59.628 Điều đã lập chỉ mục

Chấm điểm và xếp hạng

Mỗi Điều trong kho nhận điểm liên quan $s(q, d)$; mô hình xếp hạng theo điểm số.

Nhãn thật (ground truth):

aid 55075 · Luật 78/2015/QH13
"Tạm hoãn gọi nhập ngũ..."

aid 4993 · Luật 48/2019/QH14
"Sửa đổi, bổ sung Luật Nghĩa vụ quân sự..."

Đầu ra mong muốn

aid 55075
aid 4993



Câu hỏi nghiên cứu

Bốn câu hỏi được đặt ra:

1. Biểu diễn và lưu trữ văn bản pháp luật như thế nào để truy xuất hiệu quả?
2. Xây dựng thành phần truy xuất và xếp hạng điều luật ra sao?
3. Làm sao để tận dụng và kết hợp các tín hiệu truy xuất lại với nhau để cho kết quả tốt hơn?
4. Chọn số điều luật phù hợp để trả về cho mỗi câu hỏi như thế nào?



PHẦN 2

Dữ liệu và độ đo

Cấu trúc dữ liệu gốc

Mẫu JSON · Luật 102/2016/QH13

```
{
  "id": 226,
  "law_id": "102/2016/QH13",
  "content": [
    {
      "aid": 6412,
      "content_Article": "Trẻ em là người dưới 16 tuổi."
    }
  ]
}
```

Trích 1 trong 106 mục `content` của văn bản gốc.

Cách đọc mẫu

id, law_id xác định văn bản pháp luật.

content chứa danh sách các đơn vị Điều luật.

aid là mã Điều dùng khi truy xuất và đánh giá; **content_Article** là nội dung tương ứng.

Một văn bản → nhiều mục `content` → mỗi mục gắn với một `aid`.



DRiLL 2025: thống kê dữ liệu

Số lượng câu hỏi:

Train · 1.752 câu

19,78	1,34
Từ / câu	Điều gold / câu
min 6 · max 45	min 1 · max 9

Dev · 438 câu

19,46	1,35
Từ / câu	Điều gold / câu
min 11 · max 45	min 1 · max 7

Public · 312 câu

20,00	1,31
Từ / câu	Điều gold / câu
min 11 · max 42	min 1 · max 4

Private · 627 câu

19,90	1,32
Từ / câu	Điều gold / câu
min 11 · max 44	min 1 · max 5

Tài liệu pháp luật: 2.157 văn bản · 59.628 Điều



Vai trò của từng tập dữ liệu

TRAIN	DEV	PUBLIC TEST	PRIVATE TEST
1.752 câu	438 câu	312 câu	627 câu
Fine-tune reranker	**Chọn cấu hình Chọn chính sách**	**Đánh giá cuối cùng**	**Đánh giá cuối cùng**

- Train/Dev được chia 80/20 từ tập Train gốc: Dev giúp quá trình xây dựng mô hình được công bằng không làm rò rỉ thông tin cho Test.
- Tài liệu pháp luật gồm 59.628 Điều, là kho ứng viên cho quá trình truy xuất và xếp hạng.



Precision và Recall: đúng đến đâu, đủ đến đâu?

Với P_q là tập Điều luật hệ thống trả về; G_q là tập Điều luật đúng (gold) của câu hỏi q.

Precision · độ chính xác

$$\frac{|P_q \cap G_q|}{|P_q|}$$

Trong các Điều được trả về, có bao nhiêu Điều liên quan?

Recall · độ bao phủ

$$\frac{|P_q \cap G_q|}{|G_q|}$$

Trong các Điều liên quan, hệ thống tìm được bao nhiêu?

Ký hiệu @k

Chỉ xét k vị trí đầu của danh sách xếp hạng. Ví dụ, Recall@50 đo tỷ lệ Điều gold xuất hiện trong 50 ứng viên đầu.

Macro-F2: cân bằng độ chính xác và độ bao phủ

Cách DRiLL tính chỉ số

$$P_{macro} = \frac{1}{Q}\sum_q P_q, \qquad R_{macro} = \frac{1}{Q}\sum_q R_q$$

$$\text{Macro-}F_2 = \frac{5\,P_{macro}\,R_{macro}}{4\,P_{macro} + R_{macro}}$$

Macro

Mỗi câu hỏi đóng góp như nhau vào Precision và Recall tổng hợp.

F2

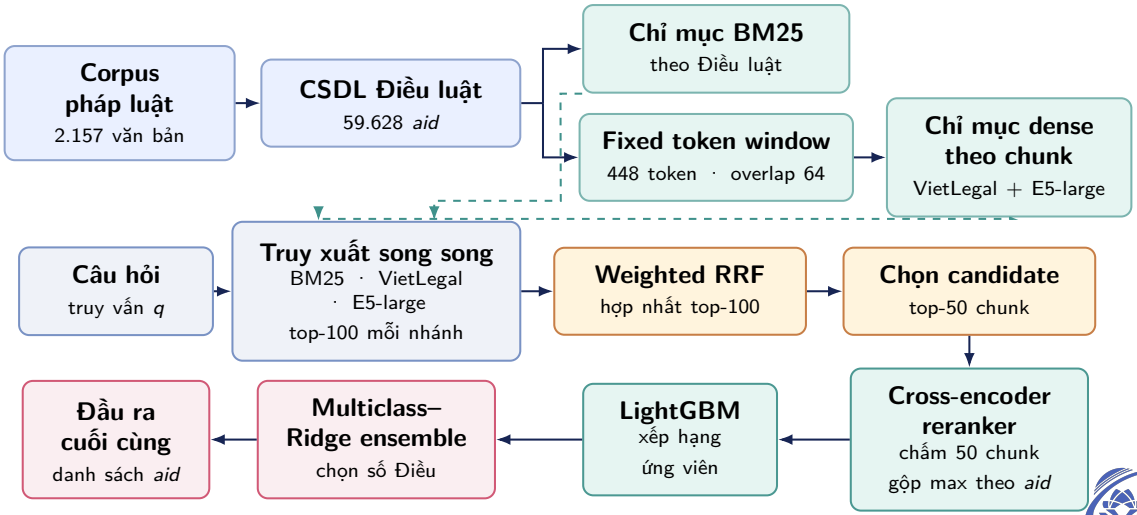
Recall được ưu tiên hơn Precision; hệ thống vẫn cần hạn chế trả về Điều không liên quan.



PHẦN 3

Phương pháp và kết quả thực nghiệm

Pipeline tổng thể



GIAI ĐOẠN 3.1

Truy xuất ứng viên

Vì sao cần biểu diễn văn bản trước khi truy xuất?

Biểu diễn văn bản giúp lập chỉ mục để tìm Điều luật theo mức độ khớp từ ngữ hoặc ngữ nghĩa.

Tín hiệu thưa (Sparse) · chỉ mục từ khóa

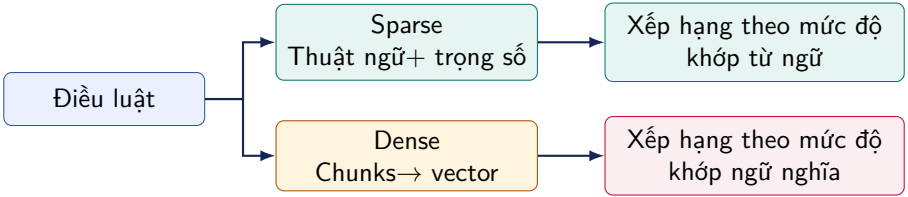
Mỗi Điều luật được biểu diễn bằng các thuật ngữ và trọng số; chỉ mục liên kết thuật ngữ với những Điều luật có chứa chúng.

→ Giúp tìm nhanh Điều luật có thuật ngữ trùng với câu hỏi.

Tín hiệu dày (Dense) · chỉ mục vector

Mỗi Điều luật chia thành các chunk được biểu diễn bằng các vector dày đặc, mã hóa thông tin ngữ nghĩa của đoạn.

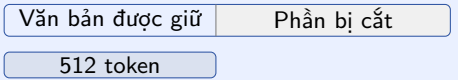
→ Giúp tìm Điều luật liên quan dù câu hỏi dùng cách diễn đạt khác.



Chunking cho mô hình dense

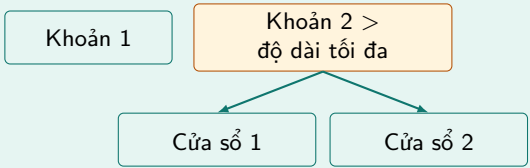
1. Đưa trực tiếp từng Điều luật cho mô hình (Article trucation)

Mỗi Điều là một chunk, tuy nhiên phần vượt quá chiều dài tối đa của mô hình sẽ bị cắt (512 token).



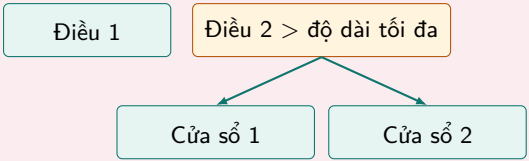
2. Cửa sổ trượt theo Khoản (Clause window)

Mỗi Khoản là một chunk; Khoản dài hơn giới hạn được chia thành các cửa sổ 448 token, chồng lấp 64.



3. Cửa sổ trượt theo Điều (Article window)

Mỗi Điều là một chunk; Điều dài hơn giới hạn được chia thành các cửa sổ 448 token, chồng lấp 64.



Ablation chunking ở giai đoạn truy xuất

Bảng 1. So sánh cách chunking tại giai đoạn truy xuất, dựa trên mô hình VietLegal-Harrier

Biểu diễn	Precision@2	Recall@2	Macro-F2@2	Recall@50	Recall@100
Article truncation (512)	0.3368	0.5732	0.5026	0.9125	0.9422
Clause window (448/64)	0.3345	0.5742	0.5022	0.9186	0.9471
Article window (448/64)	**0.3425**	**0.5808**	**0.5098**	**0.9256**	**0.9517**

Nhận xét

- Trong ba cách trình bày, Article window đạt kết quả cao nhất đặc biệt với chỉ số Recall@50.
- Article window cũng phù hợp với đơn vị truy xuất của bài toán (cấp Điều) mà không làm mất thông tin như Article truncation.

Từ nhánh đơn đến truy xuất lai (hybrid retrieval)

Sparse

Khớp từ khóa.

BM25

$$\mathrm{BM25}(q,d) = \sum_{t \in q} \mathrm{IDF}(t)\, w(t,d)$$

$$w(t,d) = \frac{f(t,d)(k_1+1)}{f(t,d) + k_1\left(1 - b + b\frac{|d|}{\mathrm{avgdl}}\right)}$$

Dense

Khớp ngữ nghĩa

Nhánh 1 · VietLegal-Harrier

Nhánh 2 · multilingual-E5-large

Hybrid

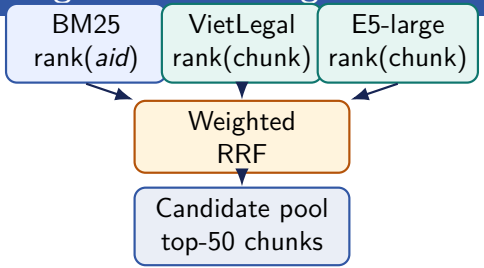
Bổ sung đa tín hiệu

Weighted RRF
Hợp nhất thứ hạng từ các nhánh.

Mỗi nhánh lấy top-100; sau hợp nhất chọn top-50 cho reranker.



Weighted RRF: công thức và ví dụ tính điểm



Công thức WRRF

$$S(c) = \sum_{m \in \mathcal{M}} \frac{w_m}{k + r_m(c)}$$

- c: chunk; $aid(c)$: Điều cha. BM25 xếp Điều, dense xếp chunk.
- r_m: hạng trong nhánh m (1 đứng đầu); thiếu hạng thì đóng góp 0.
- $\mathcal{M}$: tập nhánh; w_m: trọng số; k: hằng số làm mượt hạng.

Ví dụ thay số · BM25 theo aid cha, VietLegal/E5-large theo chunk

Chunk X (aid A)

Hạng: BM25(A)=8 · VietLegal(X)=2 · E5-large(X)=12

$$0.15/18 + 0.65/12 + 0.20/22 = 0.0716$$

Chunk Y (aid B)

Hạng: BM25(B)=1 · VietLegal(Y)=15 · E5-large(Y)=3

$$0.15/11 + 0.65/25 + 0.20/13 = 0.0550$$

$0.0716 > 0.0550$ nên Chunk X được xếp cao hơn Chunk Y.

Ablation ở giai đoạn truy xuất: thành phần nào hữu ích?

Bảng 2. Đánh giá các thành phần truy xuất đơn và lai. Cấu hình lai: top-100/nhánh, WRRF k=10, trọng số: BM25+VietLegal 0.19/0.81; VietLegal+E5-large 0.76/0.24; cả ba 0.15/0.65/0.20

First-stage components	Precision@2	Recall@2	Macro-F2@2	Recall@50
BM25	0.2511	0.4297	0.3762	0.8348
VietLegal-Harrier	0.3425	0.5808	0.5098	0.9256
multilingual-E5-large	0.3174	0.5347	0.4703	0.9106
BM25 + VietLegal	0.3482	0.5846	0.5147	0.9338
VietLegal + E5-large	0.3539	0.5934	0.5227	0.9350
BM25 + VietLegal + E5-large	**0.3573**	**0.5951**	**0.5252**	**0.9387**

Thành phần đơn: đo trực tiếp trên dev. Thành phần lai: dùng OOF 5-fold, tune trên 4 folds và chấm fold còn lại.



GIAI ĐOẠN 3.2

Xếp hạng lại ứng viên

Cross-encoder reranking

Vì sao cần reranking?

Truy xuất lai ưu tiên tìm được nhiều ứng viên liên quan; thứ hạng hợp nhất chưa so sánh trực tiếp câu hỏi với từng đoạn. Cross-encoder đọc **câu hỏi và chunk cùng lúc** để chấm lại mức độ phù hợp, tập trung vào 50 chunk đầu để giới hạn chi phí.

Ví dụ minh họa thứ hạng

Câu hỏi: Điều kiện nào được hỏi?

Ứng viên	Trước	Sau rerank
A: trùng nhiều từ, nhưng lệch ý hỏi	4	7
B: ít từ trùng, nhưng đúng ý hỏi	18	1

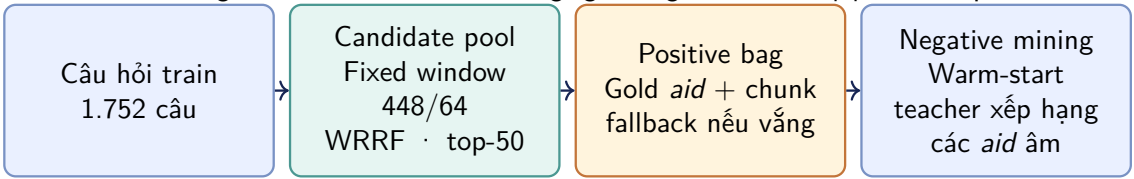
Các bước

1. Lấy top-50 chunk từ bước hợp nhất.
2. Chấm từng cặp câu hỏi–chunk.
3. Gộp điểm chunk bằng max theo *aid*.
4. Xếp hạng lại các Điều luật.



Fine-tuning: tạo dữ liệu giám sát

Chỉ dùng 1.752 câu hỏi train; first-stage giữ cùng cấu hình với pipeline cố định.

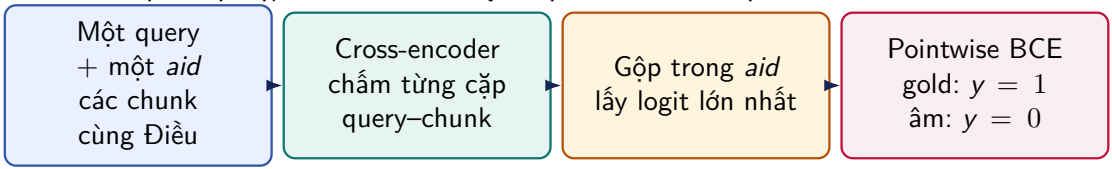


Giữ dev riêng

438 câu dev không tham gia mining hay fine-tuning; teacher chỉ giúp chọn mẫu âm khó, không quyết định nhãn gold.

Fine-tuning: mô hình học như thế nào?

Mỗi ví dụ là một cặp **câu hỏi–Điều luật**; một Điều có thể được biểu diễn bởi nhiều chunk.



Để học qua nhiều chunk

Seeded-cycle chọn tối đa 4 chunk cho mỗi *aid* trong một epoch, luân phiên có kiểm soát để các chunk đều được gặp qua các epoch.

Fine-tuning: cấu hình và checkpoint

Cấu hình huấn luyện

- Khởi tạo từ Vietnamese reranker đã huấn luyện.
- Đầu vào tối đa 512 token; pointwise MIL BCE, gộp max theo *aid*.
- Learning rate 2×10^{-5}; batch hiệu dụng 16 trên 2 GPU.
- Chạy 3 epoch; lịch giảm learning rate được tính theo kế hoạch 5 epoch.

Lưu và so sánh

- Checkpoint epoch 1/2/3: step 1234/2471/3709.
- Chấm trên cùng handoff của 438 câu dev.
- Epoch 3 tốt nhất nếu chỉ xét reranker fixed top-2; epoch 1 được đưa vào baseline submission hiện tại.

Luồng sau fine-tuning

Epoch 1 / checkpoint 1234 → LightGBM enhanced_v2 → chính sách Multiclass–Ridge.

Ablation fine-tuning: reranker-only

Cùng pool ứng viên dev (438 câu) · fixed window 448/64 · tắt reference. Top-30 gần độ sâu LightGBM đọc nhất (trung bình 30,5 aid/query).

Bảng 3. Reranker-only: kết quả tại fixed top-30 trên dev

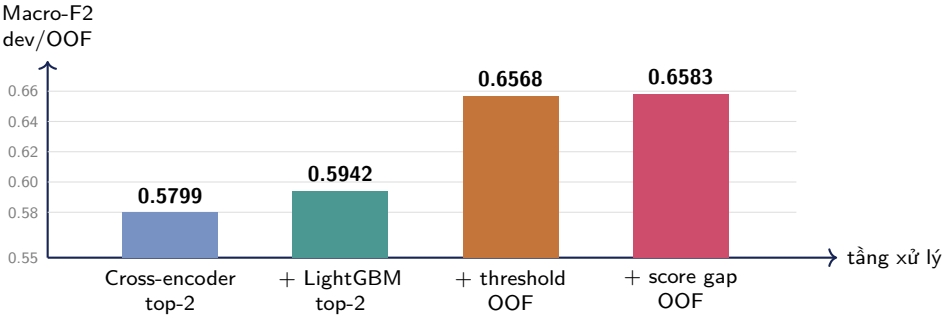
Mô hình	Precision@30	Recall@30	Macro-F2@30
Epoch 3	0.0404	0.9270	**0.1719**
Epoch 2	0.0402	0.9240	0.1713
Epoch 1	0.0400	0.9214	0.1704
Chưa fine-tune	0.0395	0.9124	0.1682

Kết luận

Epoch 3 dẫn đầu ở cutoff này; đây là đại diện gần đúng cho độ dài input LightGBM, không phải độ sâu đầu vào chính xác (LightGBM nhận toàn bộ danh sách, tối đa 50 aid).

Từng tầng làm thay đổi kết quả ra sao?

Các mốc dev/OOF để kể tiến trình pipeline; đây không phải ablation một biến duy nhất.



Diễn giải: Chọn số điều luật là bài toán riêng; các mốc kể tiến trình, không phải ablation một biến.

GIAI ĐOẠN 3.3

Tổng hợp tín hiệu

LightGBM: kết hợp tín hiệu reranker

Tín hiệu đầu vào

- Điểm/thứ hạng từ retriever
- Score cross-encoder và chênh lệch trong query
- Tín hiệu từ query, chunk và article

Huấn luyện có kiểm soát

- 61 đặc trưng (`enhanced_v2`)
- Chia fold theo query
- OOF dùng để chọn chính sách đầu ra

LightGBM học sắp hạng lại candidate; chính sách cardinality quyết định trả bao nhiêu article.



Ablation sau reranker: checkpoint và chính sách

Cùng dev và đặc trưng. LightGBM nhận toàn bộ article sau rerank (tối đa 50 aid/query; 13.348 dòng, trung bình 30,5/query). Macro-F2 ở bảng là chính sách đầu ra.

Bảng 4. Macro-F2 theo checkpoint và chính sách đầu ra

Mô hình	Fixed top-2	Threshold + fallback 2	Nested OOF score-gap	Pooled OOF score-gap
Chưa fine-tune	0.6020	0.6702	0.6525	0.6622
Epoch 1	**0.6217**	**0.6910**	0.6759	0.6773
Epoch 2	0.6188	0.6788	0.6799	0.6862
Epoch 3	0.6097	0.6641	**0.6821**	**0.6901**

Vì sao thứ hạng khác?

Epoch 3 đứng đầu khi chỉ xét reranker fixed top-2. Sau LightGBM, checkpoint tốt nhất phụ thuộc chính sách: epoch 1 dẫn đầu fixed top-2 và threshold; epoch 3 dẫn đầu score-gap. Threshold và pooled score-gap được chỉnh trên dev; nested OOF score-gap là ước lượng so sánh thận trọng hơn. Đây là các mục tiêu khác nhau, không phải kết quả mâu thuẫn.

GIAI ĐOẠN 3.4

Chọn số Điều luật đầu ra

Chính sách cardinality: bốn cách chọn số Điều luật

Sau khi xếp hạng ứng viên, mỗi chính sách quyết định trả về bao nhiêu Điều luật.

1. Fixed top-k

Luôn lấy đúng k Điều đứng đầu. Mốc đối chứng đơn giản, không thích nghi theo câu hỏi.

2. Score gap

Xét chênh lệch điểm giữa các Điều liền kề; chọn vị trí có khoảng cách lớn để xác định điểm dừng.

3. Multiclass–Ridge ensemble

Dự đoán trực tiếp số Điều cần trả về từ các tín hiệu của danh sách đã xếp hạng.

Chính sách được chọn cho baseline hiện tại.

4. Fold-safe learned stopping

Đánh giá tuần tự từng tiền tố của danh sách và dự đoán nên tiếp tục hay dừng; được chọn làm phương pháp đối chiếu bổ sung.



Kết quả thực nghiệm các chính sách cardinality

Bảng 5. Macro-F2 trên Codabench public và private

Chính sách	Public F2	Private F2
Fixed top-2	0.5989	0.5552
Score gap	0.6551	0.6047
Fold-safe learned stopping	0.6672	0.6123
Multiclass–Ridge · baseline hiện tại	**0.6978**	**0.6825**

Fixed top-2, score gap và learned stopping: pool-50, checkpoint 1208, LightGBM enhanced_v2. Multiclass–Ridge: baseline hiện tại, fixed 448/64, checkpoint 1234. Điểm test chỉ dùng báo cáo.



Đối chiếu kết quả trên DRiLL

Bảng 6. Macro-F2 trên public/private test. Xếp theo điểm private test giảm dần

Thứ tự	Hệ thống	Public F2	Private F2
1	EDM	0.5982	**0.7261**
2	FPT IS	**0.7426**	0.6966
3	CUDO	0.7345	0.6955
4	Nhóm 18	0.6978	0.6825
5	Berry	0.4456	0.6710
6	IUH.TD	0.6337	0.6521
7	brain_rot	0.7032	0.6495
8	AImba	0.6473	0.6425
9	Baseline two-stage (BTC)	–	0.5512
10	Baseline BM25 (BTC)	0.2771	0.3365

PHẦN 4

Kết luận

Kết luận chính

Trả lời bốn câu hỏi nghiên cứu

1. **Biểu diễn văn bản:** Chia mỗi điều luật thành các cửa sổ cố định 448 token, chồng lấp 64 token; trong các cấu hình đã so sánh, cách này cho kết quả dev tốt hơn các cách chia cấu trúc.

2. **Truy xuất và xếp hạng:** Dùng BM25 cùng hai dense retriever để lấy ứng viên; cross-encoder pointwise-MIL (epoch 1) chấm điểm chunk, rồi gộp điểm về điều luật bằng max.

3. **Kết hợp tín hiệu:** Hợp nhất thứ hạng BM25, VietLegal và E5-large bằng weighted RRF (0.15/0.65/0.20), giữ top-50; LightGBM enhanced_v2 tiếp tục khai thác 61 đặc trưng trên danh sách đã rerank.

4. **Chọn số điều luật:** Multiclass–Ridge ensemble chọn số kết quả thích nghi theo từng câu hỏi, với chính sách được xác định trên dev thay vì dùng một cutoff cố định.



Giới hạn dữ liệu và mô hình

Thiếu ngữ cảnh pháp lý

Một phần dữ liệu thiếu tên văn bản và cấu trúc Chương/Mục của Điều.

Hướng xử lý: bổ sung metadata từ nguồn chính thức. Có thể giúp truy xuất đúng ngữ cảnh hơn.

Khoảng cách ngữ nghĩa

Cách hỏi đời thường khác cách diễn đạt trong luật.

Hướng xử lý: thử mở rộng query hoặc thêm tóm tắt Điều; có thể nối câu hỏi với ngôn ngữ pháp lý tốt hơn.

Giới hạn 512 token

Cross-encoder có thể bỏ sót ngữ cảnh khi cặp đầu vào quá dài.

Hướng xử lý: thử reranker dài ngữ cảnh. Có thể giữ đủ bằng chứng hơn, nhưng VRAM và thời gian có thể vượt tài nguyên hiện tại.

Hướng tiềm năng từ các đội DRiLL

Tiêu đề và tín hiệu LLM

EDM dùng tiêu đề và đặc trưng LLM; FPT IS tăng cường dữ liệu bằng LLM.

Tiềm năng: thêm tín hiệu ngữ nghĩa cho truy xuất.
Chi phí: sinh dữ liệu, kiểm tra độ đúng và lưu cache.

Xếp hạng nhiều tầng

EDM lọc ứng viên qua LambdaMART rồi LightGBM.

Tiềm năng: chuyên biệt hóa từng tầng xếp hạng.
Chi phí: tính đặc trưng và chạy nhiều lượt xếp hạng.

Hard-negative mining

ViDRILL huấn luyện với các ứng viên âm khó.

Tiềm năng: giúp reranker phân biệt ứng viên sát nghĩa hơn.
Chi phí: mining và huấn luyện lại; có thể thử quy mô nhỏ trước.

Ưu tiên theo tài nguyên

Các hướng này có thể cải thiện chất lượng, nhưng triển khai đầy đủ có thể vượt ngân sách GPU, thời gian và API hiện tại. Ưu tiên thử hard negatives trước; mở rộng tiếp nếu lợi ích xứng đáng chi phí.

Đây là hướng nghiên cứu, chưa phải kết quả đo của nhóm.

Tài liệu tham khảo

Vuong et al. (2025). DRiLL Shared Task 2025: The Challenge of Deep Retrieval in the Expansive Legal Landscape. [ACL Anthology]

Ke et al. (2017). LightGBM: A Highly Efficient Gradient Boosting Decision Tree. NeurIPS. [NeurIPS]

Wang et al. (2024). Multilingual E5-large Text Embeddings: A Technical Report. [arXiv]

Tran et al. (2025). ViDRILL: A Multi-Stage Retrieval Framework for Vietnamese Legal Document Search. [ACL Anthology]

Hoai, Hung, and Hieu (2025). Data Augmentation and Hierarchical Chunking for Deep Retrieval in the Expansive Legal Landscape. [ACL Anthology]

Hieu and Do (2025). DRiLL at VLSP 2025: A Simple Two-Stage Retrieval Framework for Vietnamese Legal Document Retrieval. [ACL Anthology]

Pham, Nguyen, and Phung (2025). EDM Team's Approach in DRiLL@VLSP 2025: A Multi-Stage End-to-End Architecture for Deep Retrieval in the Expansive Legal Landscape. [ACL Anthology]

Robertson and Zaragoza (2009). The Probabilistic Relevance Framework: BM25 and Beyond. *Foundations and Trends in Information Retrieval*, 3(4), 333–389. [DOI]

Cormack, Clarke, and Buettcher (2009). Reciprocal Rank Fusion outperforms Condorcet and individual rank learning methods. In SIGIR, 758–759. [DOI]

mainguyen9. VietLegal-Harrier-0.6B. Hugging Face model card. [Model card]

Chen et al. (2024). BGE M3-Embedding: Multi-Lingual, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation. [arXiv]

AITeamVN. Vietnamese_Reranker. Hugging Face model card. [Model card]



Cảm ơn thầy và các bạn!

Nhóm 18

Trao đổi và câu hỏi